

Nama: Sebastian Abe Santoso

NIM: 2410817210002

MK: Data Analitik

Tugas: Profiling Time-series dan Non time-series dataset

I

Pendahuluan

1.1 Latar Belakang

Kualitas data adalah salah satu faktor penting dalam proses analisis data. Dalam bidang ini, ada prinsip yang berbunyi “*Garbage In, Garbage Out*”, yaitu ketika kualitas data yang digunakan buruk, maka analisis pun akan menjadi buruk. Oleh karena itu, sebelum data digunakan, diperlukan proses pemeriksaan untuk memahami struktur data serta mengidentifikasi jika ada permasalahan kualitas data.

Salah satu proses yang biasanya dilakukan adalah data profiling, yaitu pemeriksaan data secara sistematis untuk memperoleh gambaran mengenai struktur, karakteristik, dan kualitas suatu dataset. Proses ini dilakukan untuk mengidentifikasi masalah yang dapat muncul pada data, seperti nilai yang hilang, nilai yang tidak valid, nilai yang tidak konsisten, data duplikat, serta permasalahan lainnya seperti waktu yang salah. Hasil profiling kemudian dapat digunakan sebagai dasar untuk menentukan langkah pengolahan dan pembersihan data pada tahap selanjutnya.

1.2 Tujuan

Tugas data profiling ini bertujuan untuk melakukan pemeriksaan dan penilaian kualitas terhadap dua dataset, yaitu satu dataset time-series dan satu dataset non-time-series. Penilaian dilakukan secara sistematis berdasarkan enam dimensi kualitas data yang digunakan dalam materi, yaitu Completeness, Accuracy, Consistency, Validity, Uniqueness, dan Timeliness. Melalui proses ini, dapat diketahui karakteristik serta permasalahan kualitas yang terdapat pada masing-masing dataset.

1.3 Dataset yang Digunakan

Dua dataset yang akan di-profile adalah:

1. NASA FIRMS VIIRS Suomi NPP 375 m Active Fire Data (Borneo Area)

Dataset time-series yang berisi hasil deteksi satelit terhadap active fire/thermal anomaly di wilayah Borneo. Dataset ini memiliki informasi seperti lokasi, waktu akuisisi, tingkat confidence, brightness, dan Fire Radiative Power (FRP).

2. Online Shoppers Purchasing Intention Dataset

Dataset non-time-series yang berisi informasi mengenai sesi kunjungan pengguna pada situs belanja daring, termasuk aktivitas halaman, durasi kunjungan, karakteristik pengguna dan sesi, serta informasi mengenai pembelian.

1.4 Metodologi Data Profiling

Data profiling dilakukan melalui beberapa tahap pemeriksaan, yaitu:

1. Memahami struktur dan atribut dataset,
2. Pemeriksaan karakteristik dan kualitas data, yang meliputi ukuran dataset, atribut dan tipe data, nilai yang hilang, nilai unik, duplikasi, rentang nilai, pola atau data yang tidak konsisten, serta karakteristik waktu pada dataset yang memiliki atribut waktu.

Penilaian kualitas data dilakukan berdasarkan enam dimensi berikut:

- Completeness, memeriksa kelengkapan data, terutama keberadaan nilai yang hilang.
- Accuracy, menilai sejauh mana data merepresentasikan kondisi sebenarnya berdasarkan referensi, ground truth, atau pemeriksaan yang dapat dilakukan.
- Consistency, memeriksa keseragaman representasi dan format data.
- Validity, memeriksa apakah nilai data sesuai dengan aturan, format, dan rentang yang seharusnya.
- Uniqueness, memeriksa keberadaan record yang duplikat.
- Timeliness, menilai keterkaitan data dengan aspek waktu, termasuk rentang waktu dan kontinuitas data pada dataset time-series.

II

Profiling Dataset

2.1 Dataset NASA FIRMS

2.1.1 Gambaran Umum Dataset

- Nama Dataset: NASA FIRMS VIIRS Suomi NPP 375 m Active Fire Data
- Sumber: NASA Fire Information for Resource Management System (FIRMS)
- Satelit: Suomi National Polar-orbiting Partnership (S-NPP)

- Sensor: VIIRS (*Visible Infrared Imaging Radiometer Suite*)
- Resolusi: 375 meter
- Jenis Data: Time-series
- Objek Data: Deteksi *active fire* / anomali termal
- Wilayah cakupan adalah wilayah Borneo dan sekitarnya berdasarkan koordinat yang ditentukan, yaitu (106,6–119,5°BT dan 5,18°LS–9,18°LU)
- Observasi: 20 Januari 2012 – 30 Juni 2026
- Jumlah Data: 1.408.321 baris
- Jumlah Atribut: 15 kolom
- Unit Observasi: Satu hasil deteksi *active fire* pada lokasi dan waktu tertentu
- Karakteristik utama: Memiliki atribut lokasi serta tanggal dan waktu akuisisi, sehingga dapat dianalisis berdasarkan perubahan dan pola dari waktu ke waktu.

2.1.2 Struktur Dataset

Dataset terdiri dari 1.408.321 baris dan 15 kolom. Struktur atribut dan tipe datanya adalah sebagai berikut:

No.	Atribut	Tipe Data	Keterangan
1	latitude	Float	Lintang lokasi deteksi
2	longitude	Float	Bujur lokasi deteksi
3	brightness	Float	Nilai brightness temperature
4	scan	Float	Ukuran piksel pada arah scan
5	track	Float	Ukuran piksel pada arah track
6	acq_date	Object	Tanggal akuisisi data
7	acq_time	Integer	Waktu akuisisi data
8	satellite	Object	Satelit yang digunakan
9	instrument	Object	Instrumen/sensor yang digunakan
10	confidence	Object	Tingkat confidence deteksi
11	version	Integer	Versi data
12	bright_t31	Float	Brightness temperature kanal T31
13	frp	Float	Fire Radiative Power
14	daynight	Object	Kondisi siang (D) atau malam (N)
15	type	Integer	Kategori tipe deteksi

Karakteristik struktur dataset:

- Jumlah baris: 1.408.321 baris
- Jumlah kolom: 15 kolom
- Atribut numerik: 10 atribut
- Atribut kategorikal/teks: 5 atribut
- Atribut tanggal: `acq_date`
- Atribut waktu: `acq_time`
- Atribut lokasi: `latitude`, `longitude`
- Atribut temporal: `acq_date`, `acq_time`
- Tidak terdapat kolom tambahan atau kolom kosong yang tidak terdefinisi.
- Dataset memiliki struktur tabular yang konsisten dan seluruh atribut memiliki data pada setiap baris.

2.1.3 Penilaian Kualitas Data

Penilaian kualitas dataset dilakukan berdasarkan enam dimensi kualitas data, yaitu Completeness, Accuracy, Consistency, Validity, Uniqueness, dan Timeliness. Pemeriksaan dilakukan terhadap struktur, nilai, distribusi, serta karakteristik waktu pada dataset.

○ Completeness

Memeriksa jumlah *missing value* pada setiap atribut menggunakan `isnull().sum()` dan persentase kelengkapan data.

Hasil:

I. Jumlah baris: 1.408.321

II. Jumlah kolom: 15

III. Total missing value: 0

IV. Kelengkapan data: 100%

Temuan:

Tidak ditemukan nilai yang hilang pada seluruh atribut dataset.

Kesimpulan:

Dataset memiliki tingkat Completeness yang sangat baik.

○ Accuracy

Memeriksa kewajaran nilai berdasarkan karakteristik atribut dan dokumentasi dataset. Accuracy tidak dapat diverifikasi sepenuhnya hanya dari data tanpa *ground truth* atau sumber pembanding eksternal.

Hasil:

- I. Nilai numerik berada pada rentang yang dapat diamati dari data.
- II. Tidak ditemukan nilai yang menunjukkan kesalahan yang jelas.
- III. Kebenaran hasil deteksi satelit tidak dapat dipastikan hanya berdasarkan dataset.

Temuan:

Tidak ditemukan indikasi kesalahan akurasi yang dapat diverifikasi secara internal, tetapi ground truth eksternal tidak tersedia untuk memastikan seluruh deteksi benar-benar merepresentasikan kondisi di lapangan.

Kesimpulan:

Accuracy tidak dapat dinilai secara penuh hanya berdasarkan dataset.

○ **Consistency**

Memeriksa keseragaman format, representasi kategori, serta nilai unik pada atribut kategorikal menggunakan `unique()` dan `value_counts()`.

Hasil:

- I. satellite hanya memiliki nilai SNPP.
- II. instrument hanya memiliki nilai SNPP.
- III. version hanya memiliki nilai 2.
- IV. confidence hanya menggunakan kategori n, l, h.
- V. daynight hanya menggunakan D dan N.
- VI. type hanya menggunakan kode 0, 2, 3.
- VII. acq_date menggunakan format tanggal yang konsisten.

Temuan:

Tidak ditemukan variasi penulisan atau representasi kategori yang tidak konsisten.

Kesimpulan:

Dataset memiliki Consistency yang baik.

○ **Validity**

Memeriksa apakah nilai berada pada rentang atau kategori yang sesuai dengan karakteristik atribut.

Hasil:

Atribut	Rentang / Nilai	Hasil Pemeriksaan
latitude	-5,17858 – 9,17669	Valid secara geografis
longitude	106,60306 – 119,50466	Valid secara geografis
scan	0,32 – 0,80	Tidak ditemukan nilai negatif
track	0,36 – 0,78	Tidak ditemukan nilai negatif
brightness	208,00 – 367,00	Tidak ditemukan nilai tidak wajar secara langsung
bright_t31	150,00 – 380,61	Tidak ditemukan nilai negatif
frp	0,00 – 1.114,02	Tidak ditemukan nilai negatif
acq_time	0430 – 1917	Seluruh nilai memiliki format waktu yang valid
confidence	n, l, h	Konsisten
daynight	D, N	Konsisten
type	0, 2, 3	Tidak ditemukan kode di luar kategori yang ada

Temuan:

Tidak ditemukan nilai yang secara langsung melanggar rentang atau format yang diperiksa.

Kesimpulan:

Dataset memiliki Validity yang baik berdasarkan pemeriksaan internal.

○ **Uniqueness**

Memeriksa keberadaan record duplikat menggunakan `df.duplicated()`.

Hasil:

- I. Total baris: 1.408.321
- II. Exact duplicate rows: 0
- III. Record unik: 100%

Temuan:

Tidak ditemukan baris yang memiliki isi seluruh atribut yang identik.

Kesimpulan:

Dataset memiliki Uniqueness yang sangat baik.

○ **Timeliness**

Memeriksa rentang tanggal, jumlah tanggal observasi, serta kontinuitas data untuk melihat keberadaan celah waktu pada dataset time-series.

I. Periode observasi: 20 Januari 2012 – 30 Juni 2026

II. Jumlah tanggal unik: 5.147 hari

III. Terdapat 129 hari kalender tanpa observasi.

IV. Terdapat 55 jeda observasi lebih dari satu hari.

V. Jeda terpanjang antar tanggal observasi adalah 37 hari.

VI. Jumlah observasi per hari sangat bervariasi, sehingga kepadatan observasi tidak seragam sepanjang periode.

Temuan:

Dataset memiliki cakupan waktu yang panjang, tetapi tidak memiliki observasi pada setiap hari dan kepadatan data berubah-ubah sepanjang periode.

Kesimpulan:

Dataset memiliki cakupan temporal yang baik, tetapi terdapat gap dan ketidakmerataan observasi yang perlu diperhatikan dalam analisis time-series.

2.1.4 Ringkasan Hasil Profiling Dataset 1

Hasil pemeriksaan dataset ini terhadap enam dimensi kualitas data, diperoleh ringkasan sebagai berikut:

Dimensi	Hasil Profiling	Kesimpulan
Completeness	Tidak ditemukan missing value pada 1.408.321 baris dan 15 atribut	Sangat baik
Accuracy	Tidak ditemukan indikasi kesalahan yang dapat diverifikasi secara internal, tetapi akurasi deteksi terhadap kondisi sebenarnya tidak dapat dipastikan tanpa ground truth	Tidak dapat dinilai sepenuhnya
Consistency	Format tanggal dan representasi kategori konsisten	Baik
Validity	Nilai dan kategori yang diperiksa berada dalam rentang atau format yang sesuai	Baik
Uniqueness	Tidak ditemukan exact duplicate records	Sangat baik
Timeliness	Memiliki cakupan 2012–2026, tetapi terdapat hari tanpa observasi dan ketidakmerataan jumlah observasi	Baik dengan catatan

Secara umum, dataset NASA FIRMS memiliki struktur dan kualitas data yang baik berdasarkan pemeriksaan internal. Permasalahan utama yang perlu diperhatikan adalah keterbatasan dalam menilai Accuracy dan adanya gap serta ketidakmerataan observasi pada aspek Timeliness. Temuan tersebut perlu dipertimbangkan sebelum dataset digunakan untuk analisis lebih lanjut.

2.2 Dataset Online Shoppers

2.2.1 Dataset Overview

- Nama Dataset: Online Shoppers Purchasing Intention Dataset
- Sumber: UCI Machine Learning Repository
- Jenis Data: Non-time-series / multivariate
- Objek Data: Sesi kunjungan pengguna pada situs e-commerce
- Jumlah Data: 12.330 baris
- Jumlah Atribut: 18 kolom pada file yang digunakan
- Unit Observasi: Satu sesi kunjungan pengguna
- Periode Data: Dikumpulkan dalam periode satu tahun
- Target: Revenue, yang menunjukkan apakah sesi berakhir dengan transaksi
- Atribut Data: Mencakup aktivitas halaman, durasi kunjungan, metrik website, karakteristik pengguna, serta informasi sesi seperti bulan dan hari akhir pekan
- Missing Value: Tidak ditemukan pada dataset
- Karakteristik utama: Dataset bersifat multivariat dan terdiri dari atribut numerik, kategorikal, serta Boolean. UCI mencatat bahwa dataset terdiri dari 17 fitur dan Revenue sebagai class label.
- Dataset ini digunakan sebagai dataset non-time-series karena setiap baris merepresentasikan satu sesi pengguna dan dataset tidak digunakan untuk merepresentasikan rangkaian observasi waktu yang kontinu. Meskipun terdapat atribut Month dan Weekend, kedua atribut tersebut merupakan karakteristik dari sesi, bukan penanda urutan waktu utama dataset.

2.2.2 Struktur Dataset

Dataset Online Shoppers Purchasing Intention memiliki 12.330 baris dan 18 kolom. Setiap baris merepresentasikan satu sesi kunjungan pengguna pada sebuah website e-commerce. Dataset terdiri dari atribut aktivitas pengguna, karakteristik sesi, serta variabel target yang menunjukkan apakah sesi menghasilkan transaksi.

No.	Atribut	Tipe Data	Deskripsi
1	Administrative	Integer	Jumlah halaman administratif yang dikunjungi
2	Administrative_Duration	Float	Durasi kunjungan pada halaman administratif
3	Informational	Integer	Jumlah halaman informasional yang dikunjungi
4	Informational_Duration	Float	Durasi kunjungan pada halaman informasional
5	ProductRelated	Integer	Jumlah halaman terkait produk yang dikunjungi
6	ProductRelated_Duration	Float	Durasi kunjungan pada halaman terkait produk
7	BounceRates	Float	Persentase kunjungan yang meninggalkan website setelah satu halaman
8	ExitRates	Float	Persentase halaman yang menjadi halaman terakhir dalam sesi
9	PageValues	Float	Nilai halaman berdasarkan kontribusinya terhadap transaksi
10	SpecialDay	Float	Kedekatan waktu sesi dengan hari khusus atau hari libur
11	Month	Object	Bulan ketika sesi terjadi
12	OperatingSystems	Integer	Sistem operasi yang digunakan pengguna
13	Browser	Integer	Browser yang digunakan pengguna
14	Region	Integer	Wilayah geografis pengguna
15	TrafficType	Integer	Jenis sumber lalu lintas menuju website
16	VisitorType	Object	Jenis pengunjung, seperti pengunjung baru atau kembali
17	Weekend	Boolean	Menunjukkan apakah sesi terjadi pada akhir pekan
18	Revenue	Boolean	Menunjukkan apakah sesi menghasilkan transaksi

Karakteristik struktur dataset:

- Jumlah baris: 12.330
- Jumlah kolom: 18
- Atribut numerik: 13 kolom

- Atribut kategorikal/teks: 3 kolom
- Atribut boolean: 2 kolom
- Atribut target: Revenue
- Atribut kategorikal utama: Month dan VisitorType
- Atribut sesi pengguna: aktivitas halaman, durasi kunjungan, bounce rate, exit rate, dan page value
- Atribut pengguna/sesi: operating system, browser, region, traffic type, dan visitor type
- Atribut waktu: Month dan Weekend

2.2.3 Penilaian Kualitas Data

Penilaian dilakukan berdasarkan enam dimensi kualitas data: Completeness, Accuracy, Consistency, Validity, Uniqueness, dan Timeliness.

○ Completeness

Memeriksa jumlah missing value pada setiap atribut menggunakan `isnull().sum()` dan persentase kelengkapan data.

Hasil:

- I. Jumlah baris: 12.330
- II. Jumlah kolom: 18
- III. Total missing value: 0
- IV. Kelengkapan data: 100%

Temuan:

Tidak ditemukan nilai yang hilang pada seluruh atribut dataset.

Kesimpulan:

Dataset memiliki tingkat Completeness yang sangat baik.

○ Accuracy

Memeriksa kewajaran nilai berdasarkan karakteristik atribut dan dokumentasi dataset. Accuracy tidak dapat diverifikasi sepenuhnya hanya dari data tanpa *ground truth* atau sumber pembandingan eksternal.

Hasil:

- I. Nilai durasi tidak memiliki nilai negatif.
- II. BounceRates dan ExitRates berada pada rentang 0–0,2.
- III. SpecialDay berada pada rentang 0–1.

IV. Nilai Revenue hanya menunjukkan kondisi transaksi atau tidak transaksi.

Temuan:

Tidak ditemukan indikasi kesalahan nilai yang dapat diverifikasi secara internal. Namun, kebenaran setiap nilai terhadap aktivitas pengguna sebenarnya tidak dapat dipastikan tanpa sumber ground truth.

Kesimpulan:

Accuracy tidak dapat dinilai secara penuh hanya berdasarkan dataset.

○ **Consistency**

Memeriksa konsistensi format dan kategori pada atribut kategorikal serta representasi nilai Boolean.

Hasil:

I. Month memiliki 10 kategori dengan format singkatan bulan yang konsisten. Januari dan April tidak terdapat dalam dataset.

II. VisitorType memiliki 3 kategori: Returning_Visitor, New_Visitor, dan Other.

III. Weekend menggunakan nilai Boolean True/False.

IV. Revenue menggunakan nilai Boolean True/False.

V. Tidak ditemukan variasi penulisan kategori yang jelas menunjukkan ketidakkonsistenan.

Temuan:

Representasi kategori dan Boolean konsisten di seluruh dataset.

Kesimpulan:

Dataset memiliki Consistency yang baik.

○ **Validity**

Memeriksa apakah nilai numerik berada pada rentang yang sesuai dan apakah kategori memiliki nilai yang valid.

Hasil:

Atribut	Rentang / Nilai	Hasil
Administrative	0–27	Valid
Informational	0–24	Valid
ProductRelated	0–705	Valid

Administrative_Duration	0–3398,75	Tidak negatif
Informational_Duration	0–2549,375	Tidak negatif
ProductRelated_Duration	0–63973,52	Tidak negatif
BounceRates	0–0,2	Valid
ExitRates	0–0,2	Valid
PageValues	0–361,76	Tidak negatif
SpecialDay	0–1	Valid
OperatingSystems	1–8	Valid
Browser	1–13	Valid
Region	1–9	Valid
TrafficType	1–20	Valid

Temuan:

Tidak ditemukan nilai yang secara langsung melanggar rentang atau format yang diperiksa.

Kesimpulan:

Dataset memiliki Validity yang baik berdasarkan pemeriksaan internal.

○ **Uniqueness**

Memeriksa keberadaan baris yang identik menggunakan duplicated().

Hasil:

- I. Total baris: 12.330
- II. Exact duplicate rows: 125
- III. Baris unik: 12.205
- IV. Persentase duplikasi: sekitar 1,01%

Temuan:

Ditemukan 125 baris duplikat secara identik.

Namun, karena unit observasi dataset adalah sesi kunjungan, kemunculan nilai atribut yang sama tidak selalu berarti kesalahan. Pemeriksaan duplicated() hanya menunjukkan bahwa seluruh nilai pada beberapa baris identik.

Kesimpulan:

Dataset memiliki Uniqueness yang perlu diperhatikan karena terdapat exact duplicate records.

- **Timeliness**

Memeriksa keberadaan atribut yang berkaitan dengan waktu serta menilai keterbatasannya untuk analisis temporal. Dataset dikumpulkan dalam periode satu tahun, tetapi tidak memiliki timestamp atau tanggal spesifik untuk setiap sesi.

I. Dataset memiliki atribut Month.

II. Dataset memiliki atribut Weekend.

III. Month terdiri dari 10 kategori, yaitu Feb, Mar, May, Jun, Jul, Aug, Sep, Oct, Nov, dan Dec.

IV. Januari dan April tidak terdapat dalam dataset.

V. Tidak terdapat timestamp atau tanggal spesifik untuk setiap sesi.

VI. Dataset merupakan kumpulan sesi pengguna, bukan rangkaian observasi waktu yang kontinu.

Temuan:

Informasi waktu tersedia pada tingkat bulan dan indikator akhir pekan, tetapi tidak terdapat tanggal atau timestamp individual untuk setiap observasi. Selain itu, tidak semua bulan dalam satu tahun terdapat pada dataset.

Kesimpulan:

Timeliness pada dataset ini terbatas untuk analisis temporal karena tidak tersedia timestamp lengkap dan tidak semua bulan terdapat dalam data. Atribut waktu yang tersedia lebih berfungsi sebagai karakteristik sesi daripada indeks time-series.

2.2.4 Ringkasan Hasil Profiling Dataset 2

Berdasarkan hasil pemeriksaan terhadap enam dimensi kualitas data, diperoleh ringkasan sebagai berikut:

Dimensi Kualitas	Hasil Pemeriksaan	Kesimpulan
Completeness	Tidak terdapat missing value pada 12.330 baris dan 18 kolom.	Sangat baik
Accuracy	Tidak ditemukan indikasi kesalahan nilai secara internal, tetapi kebenaran data tidak dapat diverifikasi tanpa ground truth.	Tidak dapat diverifikasi sepenuhnya

Consistency	Format kategori Month, VisitorType, serta nilai Boolean Weekend dan Revenue konsisten.	Baik
Validity	Nilai numerik berada pada rentang yang diperiksa dan tidak ditemukan nilai negatif yang tidak sesuai.	Baik
Uniqueness	Terdapat 125 exact duplicate records atau sekitar 1,01% dari total data.	Perlu diperhatikan
Timeliness	Informasi waktu hanya tersedia melalui Month dan Weekend; tidak terdapat timestamp lengkap dan Januari serta April tidak tersedia.	Terbatas

Secara umum, dataset Online Shoppers Purchasing Intention memiliki kualitas internal yang baik, terutama dari sisi Completeness, Consistency, dan Validity. Hal yang perlu diperhatikan adalah adanya 125 exact duplicate records serta keterbatasan informasi waktu karena tidak tersedia timestamp individual.

III

Perbandingan Hasil Profiling

3.1 Table Perbandingan

Perbandingan kedua dataset yang dilakukan berdasarkan enam dimensi kualitas.

Dimensi	NASA FIRMS VIIRS	Online Shoppers Purchasing Intention
Completeness	Tidak ditemukan missing value pada 1.408.321 baris.	Tidak ditemukan missing value pada 12.330 baris.
Accuracy	Tidak ditemukan kesalahan yang dapat diverifikasi secara internal, tetapi tidak dapat dikonfirmasi tanpa ground truth.	Tidak ditemukan indikasi kesalahan secara internal, tetapi tidak dapat dikonfirmasi tanpa ground truth.
Consistency	Format dan kategori seperti satellite, instrument, confidence, dan daynight konsisten.	Kategori Month, VisitorType, serta Boolean Weekend dan Revenue konsisten.
Validity	Nilai koordinat, waktu, dan atribut numerik berada dalam rentang hasil pemeriksaan.	Nilai numerik berada dalam rentang hasil pemeriksaan dan

		tidak ditemukan nilai yang tidak sesuai.
Uniqueness	Tidak ditemukan exact duplicate records.	Ditemukan 125 exact duplicate records atau sekitar 1,01% data.
Timeliness	Memiliki tanggal dan waktu observasi sehingga dapat dianalisis berdasarkan perubahan waktu, tetapi terdapat beberapa celah periode observasi.	Hanya memiliki informasi Month dan Weekend, tanpa timestamp individual.

3.2 Ringkasan

Kedua dataset menunjukkan karakteristik yang berbeda karena tujuan dan struktur datanya berbeda.

NASA FIRMS merupakan dataset time-series, sehingga memiliki atribut tanggal dan waktu yang memungkinkan analisis berdasarkan periode observasi.

Online Shoppers Purchasing Intention merupakan dataset non-time-series, dengan setiap baris merepresentasikan satu sesi kunjungan pengguna.

Kedua dataset memiliki Completeness yang baik karena tidak ditemukan missing value.

Pada aspek Uniqueness, dataset NASA tidak memiliki exact duplicate records, sedangkan Online Shoppers memiliki 125 baris identik.

Pada aspek Timeliness, NASA memiliki informasi waktu yang lebih detail karena menyediakan tanggal dan waktu akuisisi. Online Shoppers hanya menyediakan informasi bulan dan akhir pekan.

Untuk Accuracy, kedua dataset tidak dapat diverifikasi sepenuhnya hanya berdasarkan isi dataset karena diperlukan sumber ground truth untuk memastikan kebenaran setiap observasi.

Secara umum, kedua dataset memiliki kualitas internal yang cukup baik berdasarkan hasil pemeriksaan enam dimensi. Perbedaan utama terdapat pada struktur waktu, keberadaan duplicate records, dan tingkat detail informasi temporal yang tersedia pada masing-masing dataset.

IV

Close

4.1 Kesimpulan

Hasil data profiling terhadap NASA FIRMS VIIRS Suomi NPP 375 m Active Fire Data (Borneo Area) sebagai dataset time-series dan Online Shoppers Purchasing Intention Dataset sebagai dataset non-time-series, memberikan beberapa kesimpulan:

Kedua dataset memiliki Completeness yang baik karena tidak ditemukan missing value. Pada Consistency dan Validity, kedua dataset menunjukkan format, kategori, serta rentang nilai yang secara internal sesuai dengan atribut masing-masing.

Dimensi Accuracy tidak dapat diverifikasi sepenuhnya hanya berdasarkan data yang tersedia karena tidak terdapat ground truth untuk membandingkan setiap observasi. Pada dimensi Uniqueness, dataset NASA FIRMS tidak memiliki exact duplicate records, sedangkan Online Shoppers memiliki 125 baris duplikat identik atau sekitar 1,01% dari total data.

Pada dimensi Timeliness, NASA FIRMS memiliki informasi tanggal dan waktu observasi sehingga dapat digunakan untuk analisis temporal, meskipun terdapat beberapa celah periode observasi. Online Shoppers hanya memiliki informasi Month dan Weekend tanpa timestamp individual sehingga lebih sesuai dikategorikan sebagai dataset non-time-series.

Secara keseluruhan, berdasarkan pemeriksaan internal yang dilakukan, kedua dataset menunjukkan kualitas data yang cukup baik, dengan beberapa keterbatasan terutama pada verifikasi accuracy, duplicate records pada Online Shoppers, dan kelengkapan informasi temporal.

4.2 Saran

Berdasarkan hasil profiling yang diperoleh, beberapa saran yang dapat diberikan adalah:

Melakukan validasi lebih lanjut menggunakan sumber eksternal atau ground truth untuk meningkatkan keyakinan terhadap accuracy data.

Pada dataset Online Shoppers, memeriksa 125 exact duplicate records sebelum digunakan untuk analisis atau pemodelan lebih lanjut.

Pada dataset NASA FIRMS, memperhatikan celah periode observasi ketika melakukan analisis berdasarkan waktu agar hasil analisis tidak menganggap data sebagai observasi harian yang kontinu.

Melakukan dokumentasi dan pemeriksaan kualitas data secara berkala apabila dataset akan digunakan untuk analisis atau pemodelan lanjutan.

V

References

NASA Fire Information for Resource Management System (FIRMS). VIIRS Suomi NPP 375 m Active Fire Data.

<https://firms.modaps.eosdis.nasa.gov/>

UCI Machine Learning Repository. Online Shoppers Purchasing Intention Dataset.

<https://archive.ics.uci.edu/dataset/468/online+shoppers+purchasing+intention>